



方寸跃迁产品手册

专注企业级 AI 安全治理

保护安全于方寸之间，助力ai实现应用跃迁

产品手册 • Product White Paper

版本
v1.0.0

发布日期
2026 年 5 月

目录

三大核心产品，构建企业级 AI Agent 安全闭环



全生命周期防护

覆盖运行时观测、主动防御、安全护栏与扫描，构建 AI Agent 全生命周期防护体系



企业级可靠性

覆盖运行时观测、主动防御、安全护栏与扫描，构建 AI Agent 全生命周期防护体系



合规与可审计

覆盖运行时观测、主动防御、安全护栏与扫描，构建 AI Agent 全生命周期防护体系



开放与集成

覆盖运行时观测、主动防御、安全护栏与扫描，构建 AI Agent 全生命周期防护体系

产品概述

产品定义

Fangcun Observer 是一款企业级安全观测与主动防御平台，专为 **AI Agent Runtime** 设计。

它能够跨各种 Agent Harness，在**操作系统层捕获 Agent 的真实 side effect**，监控包括系统命令执行、文件读写和网络请求等关键行为。接入过程**无需修改业务代码**，可一键部署无感知观测服务；同时平台持续沉淀运行数据，帮助企业构建专属的 **Agent 行为基线** 并形成**自进化防御策略**。


核心能力

01

无障碍接入

开箱即用，彻底解耦 Harness

在 OS 层直接观测 Agent 的真实动作，与 Harness、框架和模型供应商完全解耦。无论运行在哪里，观测能力始终有效。



02

无感知 Runtime 观测

真实、完整的运行状态

业务代码 0 修改，Agent 无法察觉。全面覆盖关键行为，实时呈现 Agent 的真实运行状态。



03

实时干预，主动阻断

主动防御，防患于未然

基于实时行为和风险策略，对 Agent 行为进行安全评分。针对高风险操作，系统在 side effect 发生之前完成研判，并按策略放行、警告或阻断。




04

事后审计与全链路追责

行为建模，风险无处遁形

将 Runtime side effect、Agent 行为与 LLM context 关联成完成的行为图谱。支持单/多 Agent 场景的事后审计与追责，还原完整决策链路。



05

本地审计，自进化防御

数据不上云，越用越安全

从已有的工作轨迹中持续挖掘风险模式与防御经验，沉淀组织专属的 Agent 行为基线，驱动防御策略自进化，让安全能力随着业务规模一同成长。



Agent 时代的安全边界，从 OS 层开始

看见每一个动作，掌控每一条边界。



可见

行为可观测



可控

风险可阻断



可溯源

责任可溯源

Agent 时代的安全边界， 从 OS 层开始。



产品定位

Fangcun Observer 不是又一个 Agent 框架的插件，也不是套在 LLM 之上的 Prompt 防火墙。它是一套**运行在 OS / Runtime 层的企业级 Agent 安全基础设施**，与 Harness、模型供应商完全解耦。

面向对象

它面向**已经规模化部署 Agent、或即将进入规模化阶段的企业**，为安全负责人、AI 平台负责人和合规团队提供一套可观测、可阻断、可追溯、可进化的统一防御底座。让 Agent 安全从「读 Prompt、看 Log」真正升级为**理解并控制真实行为**。

三大价值主张

01

看到真实行为

穿透表象，直达本质



穿透日志和 SDK 上报，直达 OS 层 side effect，消除 sandbagging 与主动 deception 的空间。

- ✓ 全量捕获 Agent 行为的真实副作用
- ✓ 覆盖文件、网络、系统命令等操作
- ✓ 识别伪装、篡改与隐藏行为
- ✓ 构建不可抵赖的行为证据链

02

实时阻断

防患于未然，止损于萌芽



在 side effect 真正落地前完成研判与拦截，安全防线从「亡羊补牢」到「防患于未然」

- ✓ 内核级感知，毫秒级风险研判
- ✓ 阻断高危操作，避免不可逆损害
- ✓ 支持自定义策略与分级响应
- ✓ 最小化业务影响，保障连续运行

03

策略持续自进化

越用越懂，越用越安全



从组织真实运行数据中沉淀基线，从静态规则演进为具备自学习能力的防御体系，越用越强。

- ✓ 基于行为真实数据自动沉淀基线
- ✓ 持续学习与规则优化，降低误报
- ✓ 自适应业务变化
- ✓ 形成组织专属安全知识资产



统一防御底座

可观测、可阻断、可溯源、可进化的安全能力。
为企业 Agent 落地提供坚实、可信的安全底座



可观测
全局洞察



可阻断
主动防御



可观测
证据完备



可观测
持续增强

Fangcun Observer: 看得见的安全

Fangcun Observer 的五大核心能力围绕「看见 - 研判 - 阻断 - 追溯 - 进化」的闭环展开，覆盖 Agent Runtime 从启动到运行、从单 Agent 到协作链路的全生命周期。每一项能力都建立在 OS 层真实行为数据之上，互相增强，构成完整的 Agent 安全防御底座。

01



无障碍接入

开箱即用，彻底解耦
Harness



OS 层观测



跨 Harness

02



无感知观测

业务代码 0 修改，用户
Agent 双无感知。

真实 Side
effect 观测用户
Agent
双无感知

03



实施干预，主动阻断

毫秒级研判，防患于未然



风险识别



策略研判



内核阻断

04



事后审计与全链路追责

完整行为图谱，支持 multi-
agent 协作链路追溯



05



自进化防御

数据不上云，越用越安全



数据沉淀



Trace 挖掘



策略自进化

Fangcun Observer 适用于**任何**在企业内部规模化运行 Agent 的场景。以下是四类最典型的情况，覆盖从研发到生产、从单 Agent 到协作系统、从安全运营到合规审计的不同需求。

场景 01

AI Coding Agent

在研发环境下监控 Agent 的代码执行、文件读写、依赖安装、对外网络请求等行为，及时拦截 rm -rf、上传代码、外联可疑域名等危险操作。



- 代码执行监控** 监控编译运行、脚本等操作
- 文件操作保护** 监控读写、删除、压缩等行为
- 网络访问控制** 监控外链、域名解析与数据外传
- 危险操作拦截** 拦截 rm -rf 等危险操作

核心价值：保障研发资产安全

场景 02

业务自动化 Agent

在生产业务系统中保障 Agent 对内部数据、配置、下游服务的访问严格遵循最小权限，并对越权或异常调用模式实时阻断。



- 最小权限访问** 严格控制数据与资源权限
- 下游服务保护** 监控并限制对下游服务的调用
- 越权与异常检测** 实时阻断异常使用
- 安全随业务增长** 本地数据沉淀，自进化防御

核心价值：保障业务资产安全

场景 03

Multi Agent 系统

在多 Agent 协作链路中识别环境投毒、隐性串谋、跨 Agent 越权等「幕后」风险，让协作网络中每一个动作的源头都可被定位。



- 协作链路追控** 完整记录所有交互
- 告别影子威胁** 全链路溯源，直达源头
- 可控多 Agent** 提升效率，不降安全
- 0 成本接入** OS 层观测，不加安全税

核心价值：保障协作安全可控

场景 04

Agent 安全合规审计

为合规与风控团队提供可追溯、可举证的 Agent 行为完整记录，满足内部审计、监管检查与第三方安全评估的取证要求。



- 全量行为记录** 完整记录所有操作、交互
- 可追溯可举证** 提供时间线、上下文等证据链
- 合规与审计支持** 满足内部审计、监管检查
- 长期留存与导出** 数据不上云，纯本地存储

核心价值：满足合规要求，降低审计成本



全场景覆盖
适配各类 Agent
运行环境



实时防护
风险实时检测
与阻断



智能分析
持续学习进化
精准识别风险



数据本地化
数据不出企业
安全合规可控



可视化运营
仪表盘与报表
助力决策优化

产品定义

Fangcun Guard 是一款企业级 AI Agent 安全护栏。

Agent 链路中所有「作用于内容」的能力——
语义检测 / DLP 脱敏 / 拦截 / 还原——
通过同一套引擎完成。

主流 Agent 框架原生挂载，业务代码零改动。



已支持的 Agent 框架与协议，支持一键接入



Hermes



openclaw



Langchain



Dify



Coze



AutoGen



CrewAI



LlamaIndex



四大差异化能力：快、准、灵活、中文合规

Fangcun Guard 让 Agent 应用更安全、更可靠

核心特性

Fangcun Guard 围绕「快、准、灵活、中文合规」四个支柱构建，每一项都挂硬数据。

在 6 项公开 benchmark 与 7 款开源基线模型（Llama Guard 3/4、NVIDIA Nemotron、Qwen3Guard 8B/0.6B、xGuard Reasoning 8B/0.6B）的同条件对照中，同时占据准确率与延迟的右上角。

01

够快

8 ms P99• 业内最快




同行最低 Qwen3Guard-8B 238ms；
一次完整对话 4 道审核也只在 30 ms 量级
，安全检查从性能瓶颈变成基础设施。

02

够准

91.1 F1• 綜合业内第一



6项公开 benchmark 同条件评测，
综合 F1 91.1 业内高；
次名 xGuard Reasoning-8B 87.8，
甩开同行 3-21个百分点。

01

够灵活

10类风险• 阈值独立可调



Web 控制台+API 双通道，
金融严格隐私/医疗严格隐私/ 育拉满未保/
游戏要容忍极端，每类按业务自调。

01


中文& 合规

中文长尾不漏• 审计有据



中文杨景专项训练，长尾不漏过；
每次安全决策留可追溯证据，
业务方与监管都能解释。

Average F1 vs p99 Latency • 同时占据准确率与延迟的右上角。



FANGCUN GUARD · BENCHMARK

Safety classification F1 across six public benchmarks

Fangcun Guard Open-source baselines



关键洞察



综合 F1 第一
91.1

领先第二名3.3分

在6项公开基准测试中，综合F1、平均分最高，表现稳定领先。



P99 延迟低
8 ms

比第二名快5.9倍

安全检重响应更快，降低业务流程的影响。



中文能力强
97.4

误拒率更低

在中文安全评测中显著领先，更好平衡安全性与可用性。

产品概述



产品定义

Fangcun SkillWard 是一款专为 AI Agent Skills 设计的企业级安全扫描平台。

面向已在内部部署或对外分发 Skills 的企业，SkillWard 对每一个 Skill 包做

端到端安全分析：从代码、声明、依赖、运行时行为到外链内容，全链路识别凭据窃取、外联可疑域名、远程代码下载、持久化植入等典型供应链威胁。

与纯静态扫描器相比，SkillWard 把 Skill 真实 **送进 Docker 沙箱跑起来**，配合预埋蜜罐与 Runtime Guard 实时监控行为，让运行时才会暴露的风险（如写入系统配置目录、发起外部 API 请求）也能被捕获 —— 让安全决策从规则匹配 + 人工眼检升级为 **理解意图并验证真实行为**。

关键事实



30,000+

Skill 评测样本极限

覆盖真实生态中的多领域 Skill 包，持续沉淀



~99%

Docker 沙箱部署成功率

内置 Agent 自动完成依赖安装、入口探测与失败自感



3 类

扫描选择，适配不同需求


快速扫描~10s/沙箱检测
2-3 min/深度追踪 2-4 min



30%+

风险标记率

更准确的识别风险 Skill，
高风险识别率，低误检率



Fangcun SkillWard 的五大核心能力围绕**扫描 · 研判 · 验证 · 监控 · 沉淀**的闭环展开，覆盖 Skill 从入库审查、批量评测到运行时验证的全生命周期。

01



多策略静态扫描



Multi-strategy Static Scanning

覆盖已知威胁，秒级筛除

YARA 规则、正则匹配、AST 语法树多重交叉，秒级识别已知恶意模式。

02



LLM 语义研判



LLM Semantic Evaluation

理解意图，分流明确与可疑

对 Skill 代码做语义级理解，分流明确安全 / 不安全 / 可疑三类样本。

03



自主沙箱执行



Autonomous Sandbox Execution

让 Skill 真正跑起来

Docker 隔离 + 内置 Agent 自动部署，~99% 部署成功率。

04



Runtime Guard 监控



Runtime Guard Monitoring

实时捕获 + 主动诱捕

实时捕获凭据访问、外联、提权、持久化等高危行为，预埋蜜罐。

05



证据链与基线挖掘



Evidence Chain & Baseline Mining

判定可举证，基线可沉淀

全流程证据汇总与修复建议，沉淀组织专属 Skill 安全基线。

Fangcun SkillWard 适用于任何 **需要批量引入、对外分发或安全审查 AI Agent Skills** 的场景。

01

企业 skill 市场 准入审查



- 在内部 Skill 市场 / Agent Hub 入库前自动触发扫描。
- 凭据窃取、外联可疑域名、远程下载执行等高危样本直接拦截。

适用：内部skill市场

02

AI 平台第三方 Skill 评测




- 对来自社区、合作方或采购的第三方 Skill 进行安全准入评测
- 批量并行扫描 + 沙箱真实跑通，输出可向决策层出示的证据报告

适用：AI平台生态合作评估

03

Skill 发布前 CI / CD 自检




- Skill 开发团队在发布前接入安全检查，把潜在问题在 Skill 发不前修复
- 命中即在 PR 中给出修复建议，快速修复问题

适用：Skill 开发团队

04

Skill 安全合规 审计与举证



- 为合规与风控团队提供可追溯的 Skill 安全审查全记录：静态命中、LLM 研判、沙箱行为 Runtime 检测等一系列证据一并归档

适用：合规审计

关于我们 · 联系方式

关于方寸跃迁



方寸跃迁 (Fangcun Leap) 是一家专注于 **AI Agent 安全基础设施** 的科技公司。我们相信，当 Agent 开始大规模自主行动，企业真正需要的不再是另一层 Prompt 过滤或日志审计，而是一套能直达真实行为的运行时防御底座。

围绕这一判断，我们构建了 Fangcun Observer、Guard、SkillWard——让企业在 Agent 时代既能放心放手，又能始终掌控边界。

保护安全于方寸之间，
助力ai实现应用跃迁

专注企业级 AI 安全治理



联系方式

官 网

<https://fangcunleap.com>

申请试用

<https://platform.fangcunleap.com/platform/register>

商务咨询

info@fangcunleap.com

技术支持

support@fangcunleap.com

公司地址

北京市海淀区双清路双清大厦2号楼